Aplicacion del Algoritmo K-Means para la Segmentacion de Estudiantes Universitarios

Informe Academico

1. Introduccion

El clustering es una tecnica de aprendizaje no supervisado cuyo objetivo consiste en identificar grupos de registros similares sin disponer de etiquetas previas. En este trabajo se aplico K-Means para segmentar estudiantes universitarios utilizando las variables edad, horas de estudio y promedio academico.

2. Objetivo

Aplicar K-Means para obtener cuatro segmentos de estudiantes, analizar los perfiles encontrados y representar los resultados mediante una visualizacion en dos dimensiones.

3. Metodologia

Los datos fueron cargados en un DataFrame de Pandas. Posteriormente se seleccionaron las variables edad, horas_estudio y promedio_academico. Debido a que K-Means trabaja utilizando distancias, las variables fueron estandarizadas mediante StandardScaler para evitar que la escala numerica de una variable tuviera mas influencia que las restantes. Luego se ejecuto K-Means con n_clusters=4 y se asigno a cada estudiante el cluster correspondiente.

4. Resultados

Cluster	Edad promedio	Horas promedio	Promedio academico
0	28.25	11.88	2.47
1	39.75	7.33	5.18
2	51.16	4.11	7.83
3	25.33	12.33	8.46

5. Analisis de los Clusters

Cluster 0: estudiantes relativamente jovenes con muchas horas de estudio y promedio academico bajo.

Cluster 1: estudiantes de edad intermedia con dedicacion y rendimiento medios.

Cluster 2: estudiantes de mayor edad, pocas horas de estudio y rendimiento academico elevado.

Cluster 3: estudiantes jovenes con muchas horas de estudio y los mejores resultados academicos observados.

6. Discusion

Un hallazgo relevante surge al comparar los clusters 0 y 3. Ambos presentan edades y cantidades de horas de estudio muy similares. Sin embargo, sus promedios academicos son notablemente diferentes. Esto demuestra que estudiantes con niveles de dedicacion semejantes pueden presentar rendimientos academicos muy distintos. Asimismo, el cluster 2 agrupa estudiantes de mayor edad con resultados academicos elevados. El algoritmo permite detectar estos patrones, aunque no proporciona explicaciones causales sobre su origen.

7. Conclusiones

La aplicacion de K-Means permitio identificar cuatro perfiles claramente diferenciados dentro del conjunto de estudiantes. La estandarizacion previa de los datos resulto fundamental para garantizar una comparacion equilibrada entre variables. Los resultados muestran que existen grupos con comportamientos academicos distintos y que la dedicacion al estudio no siempre se refleja de manera directa en el rendimiento observado. Finalmente, K-Means demostro ser una herramienta eficaz para descubrir patrones ocultos y realizar segmentaciones significativas dentro de conjuntos de datos multivariados.